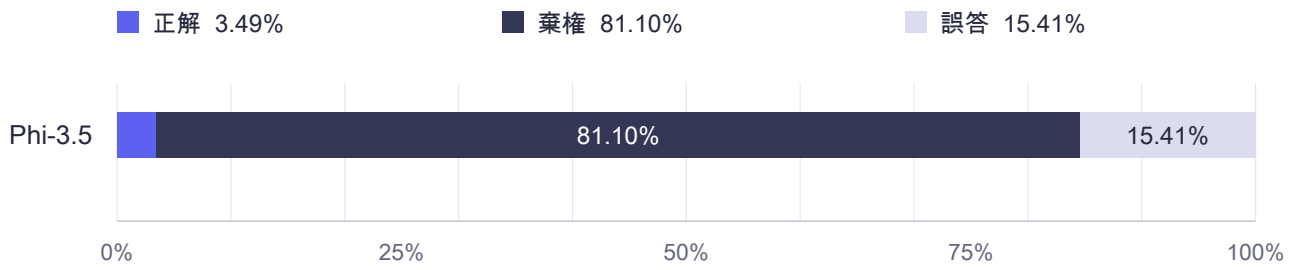
Phi-3.5 / SimpleQA

暫定評価結果

2026年10月19日

採点済み 3,783 / 4,326 問 （ 87.45% ）

割合の分母は、採点が完了した3,783問。



SimpleQA / 採点済み n = 3,783 / Qwen3.5:4bによる自動採点（暫定）

採点結果	件数	構成比
正解 CORRECT	132	3.49%
棄権 NOT_ATTEMPTED	3,068	81.10%
誤答 INCORRECT	583	15.41%
合計（採点済み）	3,783	100.00%

回答時正答率 18.46% = 132 / (132 + 583)

SimpleQA F-score 5.87%

実験条件

回答モデル	phi3.5	採点モデル	qwen3.5:4b
回答 temperature	0.1	採点 temperature	0.0
Seed（全問共通）	1052719980	回答上限	1,024 tokens

未採点 543問：反復生成エラー 1問、その他 542問。構成比の分母から除外。

回答が出力上限に達したものは 337問（採点済みの 8.91%）。

Qwen3.5:4bによる自動採点の記録値。人手検証前で、OpenAI公表値とは評価条件が異なる。

集計元：samples.jsonl / recovery_samples.jsonl（2026年10月16日・17日実行分）

最終採点応答：2026-10-17 22:02:38 JST